Introducció a la concurrència

Sistemes Operatius 2

Grau d'Enginyeria Informàtica

Objectius

La programació concurrent s'acostuma a realitzar amb múltiples fils. A partir d'ara aprendrem a:

- Programar amb múltiples fils de control.
- Sincronitzar correctament els fils entre sí.

Utilitzarem el llenguatge C, tot i que els conceptes i idees que es veuran són vàlids també a altres llenguatges com Java, Python, ... que també suporten múltiples fils.

Introducció: un procés

- Cada procés té un espai de memòria independent. Els processos no poden, per defecte, escriure a l'espai de memòria d'un altre procés.
- Per comunicar-se entre sí cal fer servir els serveis dels sistema operatiu. Per exemple, escriure a un fitxer compartit o comunicar-se via xarxa.

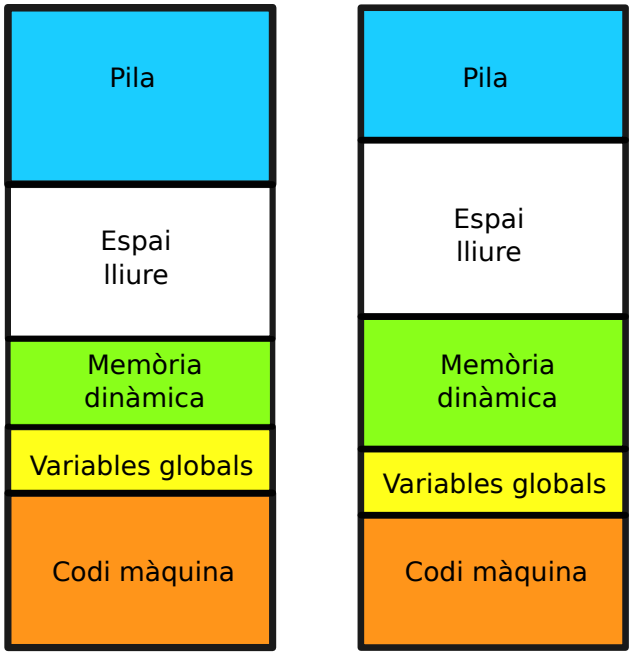

Introducció: fils

Què és un fil?

- Intuïtivament, el procés és com un llibre amb les instruccions i el fil són els ulls que executen les instruccions.

Per què es diferencia entre procés i fil?

- Un procés pot tenir múltiples fils! És com tenir múltiples ulls que executen parts diferents (o incús la mateixa) part del llibre.
- El planificador gestiona de forma independent cada fil (ho veurem més endavant).

Introducció: fils

- Els fils d'un procés comparteixen l'espai de memòria del procés. Cada fil té la seva pròpia pila i registres de la CPU i pot executar doncs una part diferent de l'aplicació.
- Per comunicar-se entre sí poden fer servir l'espai de memòria que comparteixen.

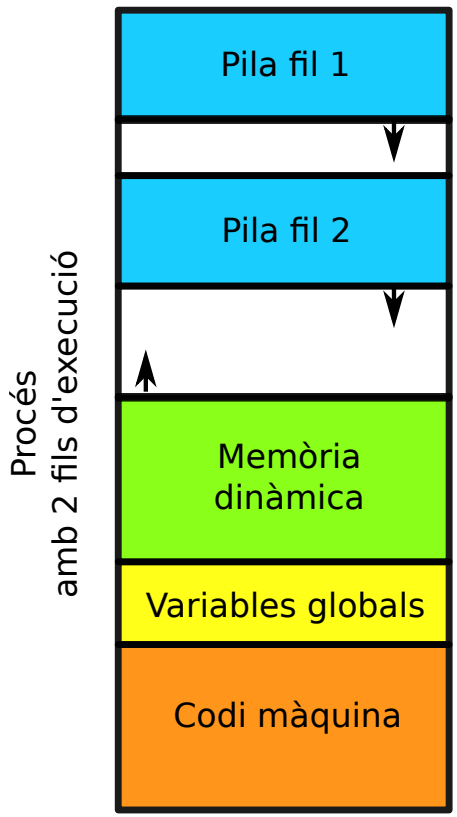


```
int global;

void funcio()
{
  int a;

  // Aixo ho executen els dos fils
}

void main(...)
{
   int fil;

   // Aixo ho executa un sol fil, una sola pila

   fil = crear_fil_nou(&funcio); // Retorna id fil creat

   // Aixo ho executa un sol fil, hi ha dues piles

   funcio();

   esperar_que_acabi_fil(fil);
}
```

Introducció: comunicació processos vs. fils

Ens els processos

- La comunicació pot ser entre processos executant al mateix o diferents ordinadors.
- Es realitza mitjançant serveis que ofereix el sistema operatiu.

En els fils

- Tots els fils executen al mateix ordinador.
- La comunicació es realitza a través de l'espai de memòria del procés.
- La complexitat se centra en la sincronització i coordinació dels fils.

Introducció: múltiples processos o múltiples fils?

- Volem dissenyar una aplicació, per exemple un servidor web.
- Quin disseny és millor: múltiples processos o múltiples fils?

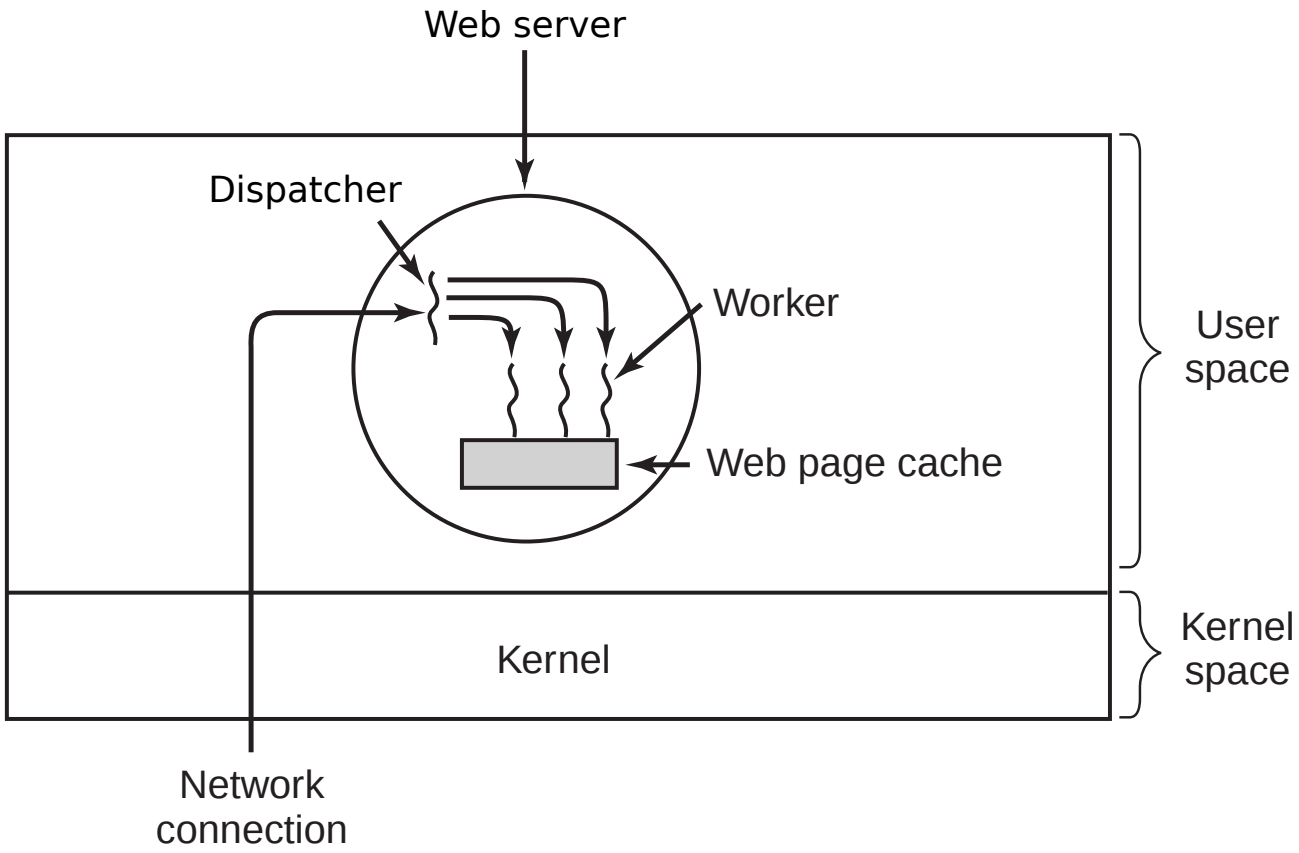

Introducció: múltiples processos o múltiples fils?

La decisió depèn de

- La quantitat de dades a compartir:
  - Utilitzar fils si hi ha moltes dades a compartir
  - Utilitzar processos si hi ha poques dades a compartir.
- La seguretat que volem implementar:
  - Si un fil fa una operació invàlida el sistema operatiu mata el procés (amb tots els seus fils).
  - Si un procés fa una operació invàlida a memòria el sistema operatiu el mata el procés, però no la resta.

Utilitzar processos és adequat doncs en aplicacions crítiques. A Google Chrome cada tabulador és un procés. A Firefox és un fil.

Introducció: programació multifil

Avantatges de la programació mutifil

- Cada fil té el seu propi estat (bloquejat, preparat, execució). Es pot millorar doncs el temps de resposta de l'aplicació.
- Simplificació del codi per tractar amb events asíncrons (ratolí, teclat, xarxa, ...)
- Facilitat per comunicar els fils entre sí (respecte fer-ho amb processos).

Atenció!

- No associar programació multifil amb sistemes multiprocessadors.
- Les avantatges de la programació multifil són evidents també amb sistemes uniprocessador.

Conceptes bàsics: processos i fils

- Elements d'un procés
  - Espai d'adreces (codi, variables globals, ...)
  - Fitxers oberts
  - La llista de fils del procés
  - Altres
- Elements propis de cada fil
  - Comptador de programa
  - Registres de la CPU
  - Pila
  - Estat (preparat, bloquejat, execució)

Conceptes bàsics: funcionament general

Suposem dues funcions, `thread_create` i `thread_wait`, per crear i esperar a un fil (aquestes no són pas les funcions "reals").

```
int global;

void funcio(int *a)
{
  // ...
}

void main(...)
{
   int fil;

   // ...

   fil = thread_create(&funcio, NULL);

   // ...

   thread_wait(fil);
}
```

La funció `thread_create`

- Té dos paràmetres: la funció d'entrada del nou fil i un paràmetre per a la funció d'entrada.
- El nou fil començarà a executar a partir de la seva funció d'entrada com si fos el seu "main".
- El fil creat mor en acabar l'execució de la seva funció d'entrada.

Conceptes bàsics: funcionament general

Suposem dues funcions, `thread_create` i `thread_wait`, per crear i esperar a un fil (aquestes no són pas les "reals").

```
int global;

void funcio(int *a)
{
  // ...
}

void main(...)
{
   int fil;

   // ...

   fil = thread_create(&funcio, NULL);

   // ...

   thread_wait(fil);
}
```

Obervacions:

- No hi ha relació pare-fill entre els fils creats i no hi ha un fil més "important" que altre per al SO (tot i que sovint es parla de fil principal i secundari).
- El fil que crea el nou fil retorna de la funció amb l'id del fil creat i continua l'execució.
- Quan el fil principal acaba el main, es mor el procés.

Conceptes bàsics: funcionament general

Suposem dues funcions "simplificades", `thread_create` i `thread_wait`, per crear i esperar a un fil.

```
int global;

void funcio(int *a)
{
  // ...
}

void main(...)
{
   int fil;

   // ...

   fil = thread_create(&funcio, NULL);

   // ...

   thread_wait(fil);
}
```

La funció `thread_wait`

- Permet que un fil esperi que un altre finalitzi.
- Si el fil al qual es vol esperar ha acabat abans de cridar a `thread_wait`, aquesta funció retorna de seguida.

Conceptes bàsics: les funcions en POSIX C

Relació entre les transparències anteriors i les funcions POSIX C que farem servir a pràctiques:

	Funció transparències
Crear fil	fil = thread_create(&funcio, arg);
Esperar fil	thread_wait(fil);

	Funció en llenguatge C (POSIX)
Crear fil	err = pthread_create(&fil, NULL, &funcio, arg);
Esperar fil	err = pthread_join(fil, NULL);

Conceptes bàsics: interferència entre fils

Cada fil té la seva pròpia pila i, per tant, fils diferents poden executar el mateix codi sense interferir-se entre sí!

```c
int imprimir(int a)
{
  int b;
  b = a + 1;
  printf("Valor %d\n", b);
  return b;
}
```

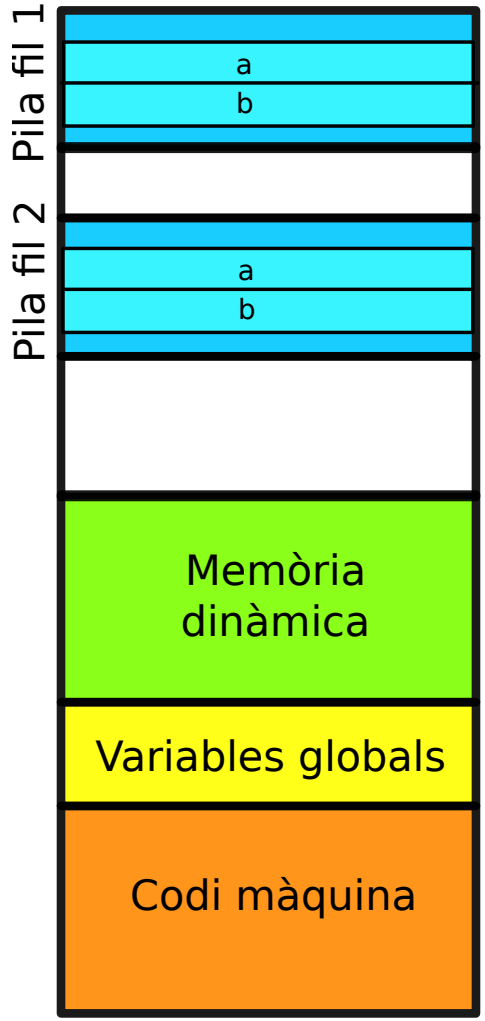

Aquest codi pot ser executat per mútiples fils a la vegada sense interferència

- Les variables a i b es guarden a la pila, i cada fil té una pila diferent.
- El valor de retorn també es guarda a la pila.

Conceptes bàsics: interferència entre fils

Cada fil té la seva pròpia pila i, per tant, fils diferents poden executar el mateix codi sense interferir-se entre sí!

```
int *processar(int a)
{
  int i, *b;
  b = malloc(sizeof(int) * a);
  for(i = 0; i < a; i++)
    b[i] = 0;
  return b;
}
```

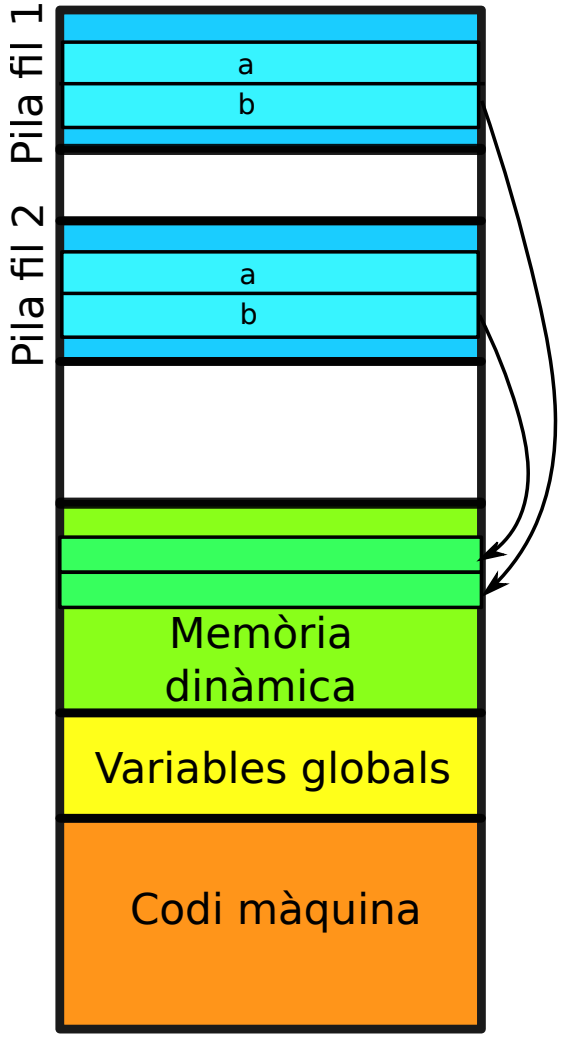

Aquest codi pot ser executat per mútiples fils a la vegada sense interferència

- En fer `malloc` es retorna una zona diferent per a cada fil.
- Compte en no escriure fora del rang del vector!

Conceptes bàsics: interferència entre fils

Quan hi pot haver problemes? En accedir (per escriptura) a variables globals o, en general, a variables compartides.

```
int global;

void funcio(int *a)
{
   global = 2;
}

void main(...)
{
   int fil;

   global = 0;

   fil = thread_create(&funcio, NULL);

   if (global == 0)
     global = 1;

   // quin valor tindra global ?

   thread_wait(fil);
}
```

Quin és el valor de `global` després de l'`if`? No se sap! Cal tenir en compte que

- El sistema operatiu és el que planifica els fils. Nosaltres no ho controlem.
- Ens faran falta funcions per sincronitzar els fils (i.e. controlar l'ordre en què s'executen el fils)

Conceptes bàsics: interferència entre fils

Quan hi pot haver problemes? En accedir (per escriptura) a variables globals o, en general, variables compartides.

```
void funcio(int *a)
{
   a[0] = 1;

   // ...
}

void main(...)
{
   int i, fil, a[5];

   for(i = 0; i < 5; i++) a[i] = 0;

   fil = thread_create(&funcio, a);

   if (a[0] == 0)
     a[0] = 2;

   // quin valor tindra a[0] ?

   thread_wait(fil);
}
```

- El segon argument de `thread_create` permet passar una variable al fil que es crea.
- Aquí la variable a estarà compartida entre els dos fils. No cal que sigui una variable global. Tindrem el mateix problema que abans.

Conceptes bàsics: seccions crítiques

Tenir en compte que:

- Els fils (o processos) poden realitzar operacions de forma independent si assegurem que les seves variables són independents entre sí.
- Aquelles parts del programa que en què els fils (o processos) accedeixen a variables compartides s'anomenen regions crítiques o seccions crítiques.
- Quan diversos fils (o processos) poden accedir per lectura o escriptura a zones de memòria compartida i no es controla l'ordre d'execució el resultat pot ser impredictible[1]. Aquesta situació se l'anomena condició de carrera (*race coditions*).

[1] Si només s'hi accedeix per lectura no hi haurà problemes. Però sí que es poden produir problemes si un fil hi accedeix per lectura i un altre per escriptura, per exemple.

Conceptes bàsics: exclusió mútua

Cal sincronitzar els fils entre sí mitjançant l'exclusió mútua (*mutual exclusion*): fils diferents no han de poder accedir a la mateixa secció crítica al mateix instant de temps.

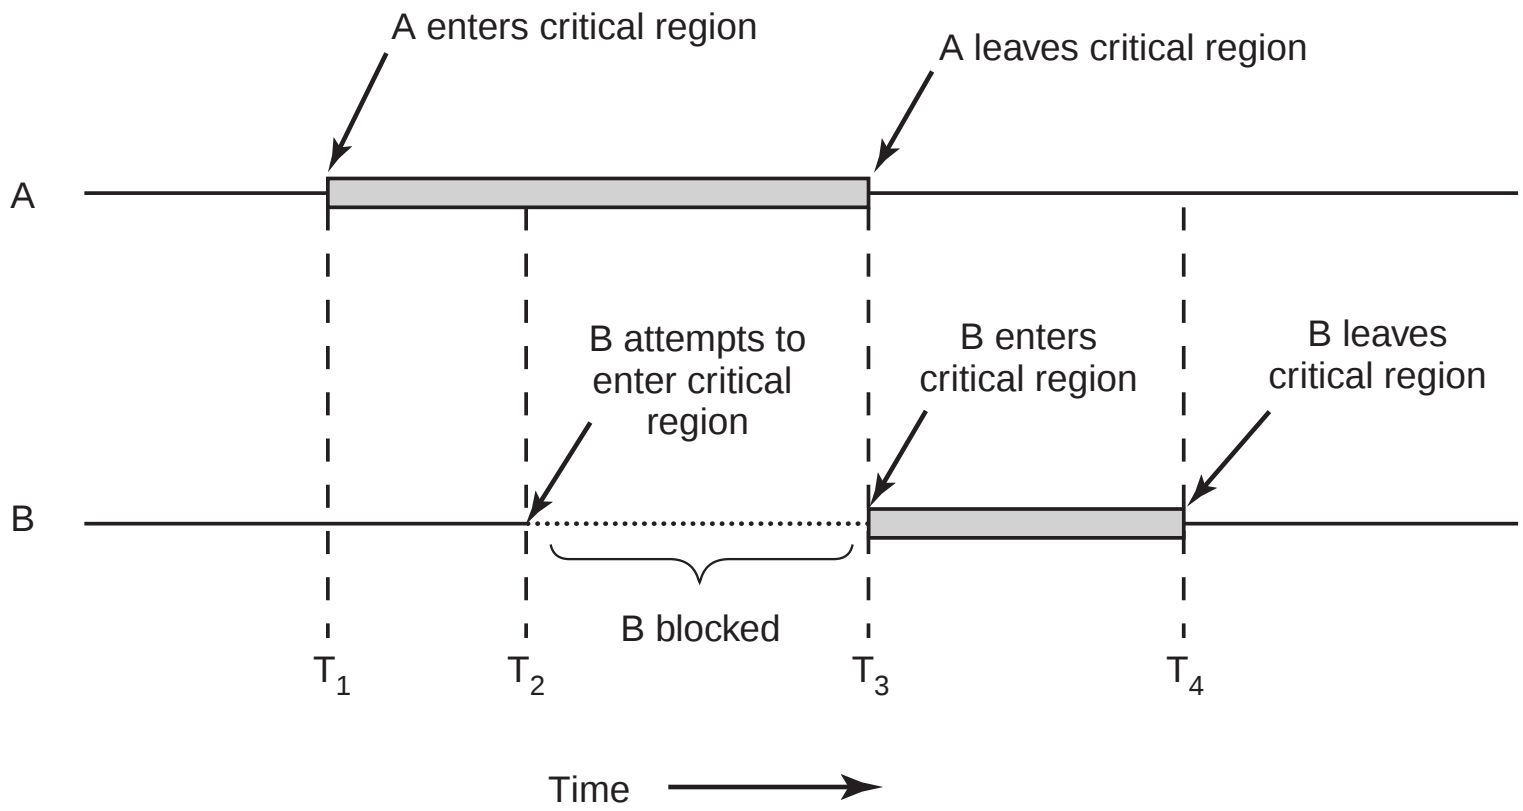

Sincronitzar múltiples fils no és senzill: Mars Pathfinder

La Mars Pathfinder va aterrar al juliol del 1997 a Mart.

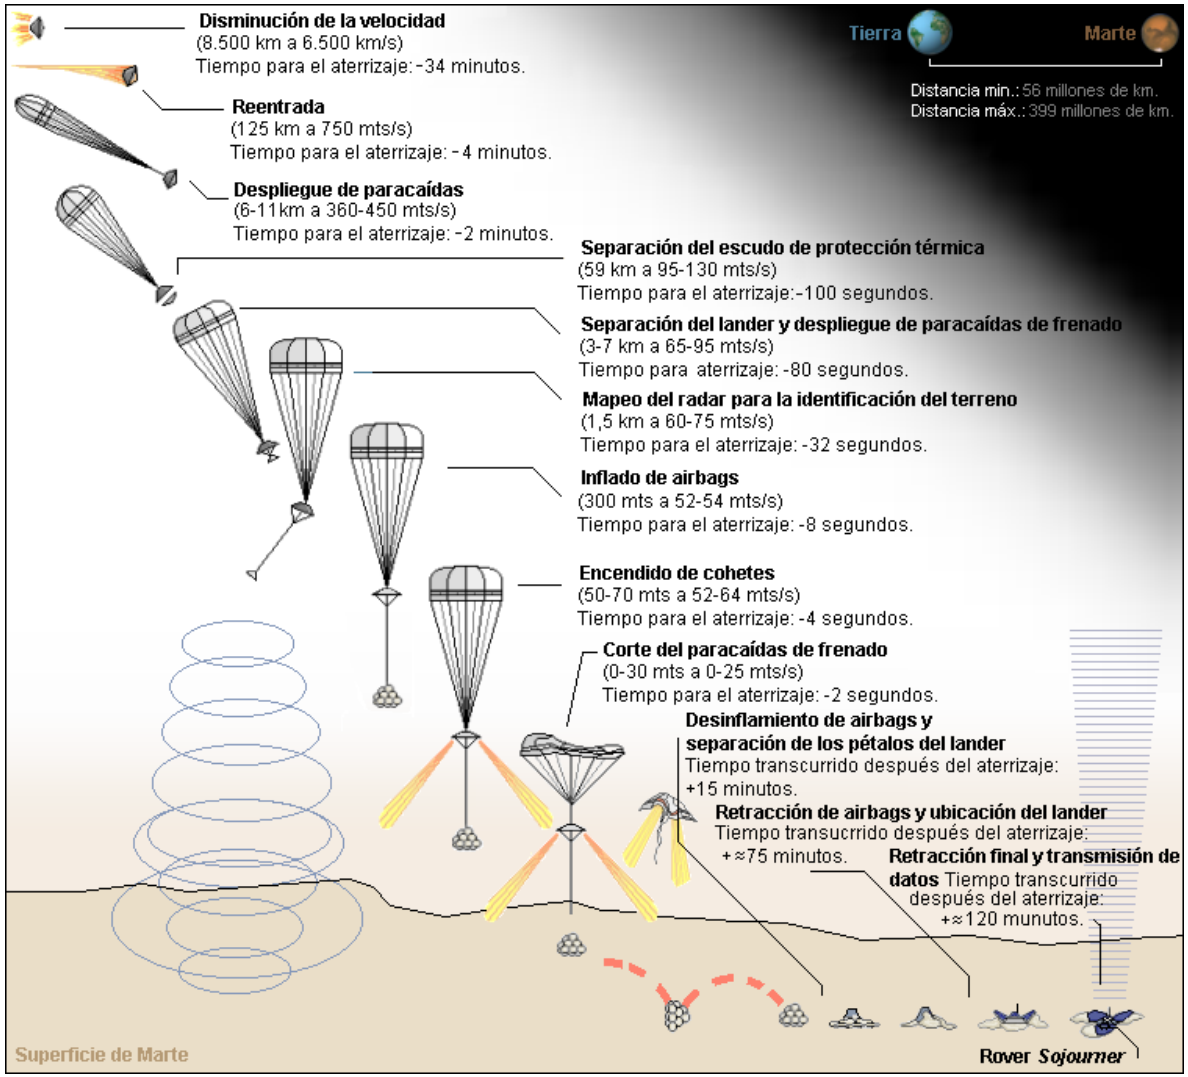

Sincronitzar múltiples fils no és senzill: Mars Pathfinder

Va ser la primera missió en enviar un vehicle tot terreny a Mart

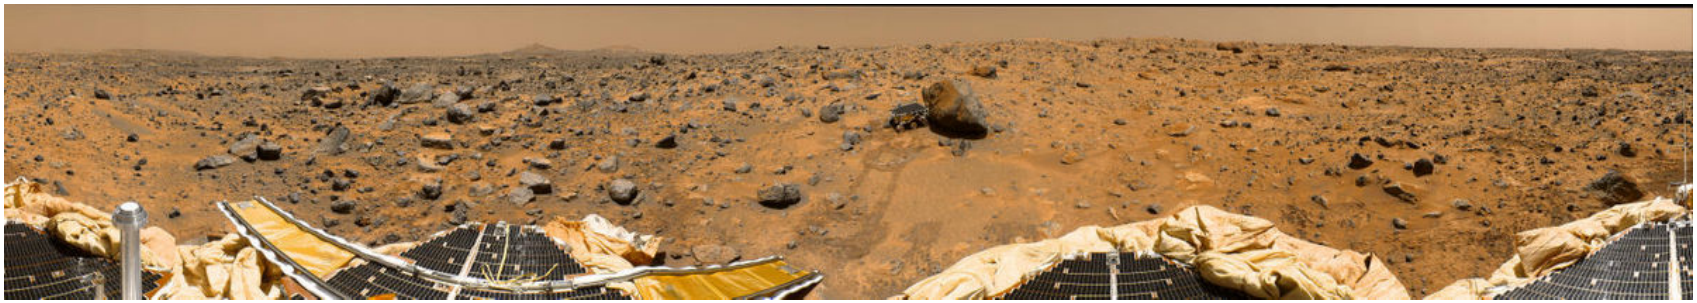

- Poc després de l'aterratge i que es comencessin a capturar dades, l'estació espacial va experimentar "resets" aleatoris del sistema.
- La premsa deia que l'ordinador estava rebent masses dades...
- Però el problema real era degut a un problema de sincronització de fils!

Exclusió mútua: motivació

Anem a veure un exemple per demostrar la necessitat de sincronitzar múltiples fils. Recordem les funcions per crear i esperar a un fil:

	Funció transparències
Crear fil	fil = thread_create(&funcio, arg);
Esperar fil	thread_wait(fil);

	Funció en llenguatge C (POSIX)
Crear fil	err = pthread_create(&fil, NULL, &funcio, arg);
Esperar fil	err = pthread_join(fil, NULL);

Exclusió mútua: motivació

```c
#define ITERATIONS 1000

int a;

void *thread_fn(void *arg)
{
  int i;
  for(i = 0; i < ITERATIONS; i++)
    a++;

  return ((void *)0);
}

int main(void)
{
  pthread_t ntid[2];
  int i;

  a = 0;

  for(i = 0; i < 2; i++)
     pthread_create(&(ntid[i]), NULL, thread_fn, NULL);

  for(i = 0; i < 2; i++)
     pthread_join(ntid[i], NULL);

  printf("Valor d'a: %d\n", a);
}
```

Codi `suma_fils.c`

1. Compilar el codi amb

   ```
   $ gcc suma_fils.c -o suma_fils -lpthread
   ```

2. Executar amb diversos valors de ITERATIONS. S'imprimeix el resultat correcte per pantalla?

Operacions atòmiques

Una operació atòmica és aquella que no pot ser interrompuda per un canvi de context.

Suposarem les següents característiques (realistes) de les màquines:

- Els tipus bàsics (int, float, double, ...) s'emmagatzemen a memòria i es poden llegir i escriure amb operacions atòmiques.
- Les variables es manipulen carregant aquestes a un registre (atòmic), operant sobre elles utilitzant els registres (no necessàriament atòmic) i emmagatzemant el resultat un altre cop a memòria (atòmic).
- Cada fil té els seus propis registres i la seva pròpia pila. Aquests es carreguen en memòria a cada canvi de context.

Operacions atòmiques

Suposem un sistema uni-processsador. Al codi que hem vist abans:

- Suposem a = 0.
- A la taula es mostren les operacions atòmiques.
- Nosaltres hem suposat que s'executa d'aquesta forma (que dóna el resultat correcte).

T	fil 1: operació a++	fil 2: operació a++
1	Carregar en registre la variable a	
2	Incrementar la variable a (=1)	
3	Desar en memòria la variable a	
4	Canvi de context	
5		Carregar en registre la variable a
6		Incrementar la variable a (=2)
7		Desar en memòria la variable a
8		

Operacions atòmiques

Suposem un sistema uni-processsador. Al codi que hem vist abans:

- Suposem `a = 0`.
- Si dos fils fan `a++`, es possible que el resultat no sigui 2?

T	fil 1: operació a++	fil 2: operació a++
1	Carregar en registre la variable a	
2	Canvi de context	
3		Carregar en registre la variable a
4		Incrementar la variable a (=1)
5		Desar en memòria la variable a
6		Canvi de context
7	Incrementar la variable a (=1)	
8	Desar en memòria la variable a	

Operacions atòmiques

A l'exemple anterior:

- El resultat de realitzar a++ per 2 fils pot ser 1 o 2, depenent d'on es faci el canvi de context.
- L'operació a++ és una regió crítica: una operació a què accedeixen (per escriptura) múltiples fils a la vegada.
- En general, l'accés concurrent de múltiples fils a variables compartides (llistes, ...) pot portar a un resultat no consistent.

Operacions atòmiques

Atenció!

- En sistemes multiprocessador no cal que es doni un canvi de context perquè es produeixi aquest problema. Tot depèn del "protocol" que es faci servir per mantenir sincronitzada la memòria cau (cache).

T	fil 1, processador 1: operació a++	fil 2, processador 2: operació a++
1	Carregar en registre la variable a	Veu el bus bloquejat
2	Incrementar la variable a (=1)	Carregar en registre la variable a
3	Desar en memòria la variable a	Incrementar la variable a (=1)
4		Desar en memòria la variable a

Funcions lock i unlock

Objectiu

- Assegurar exclusió mútua a les seccions crítiques entre múltiples fils.

Com ho farem?

- Dissenyarem dues funcions, lock i unlock, utilitzades per entrar i sortir de la regió crítica.

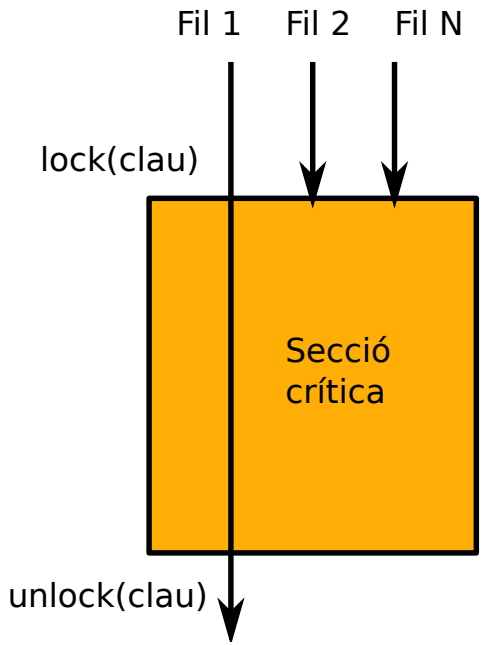

- Les funcions lock i unlock tenen una variable, la clau, compartida entre els fils.
- Funció lock(a): agafar la clau "a" (només un fil pot agafar-la).
- Funció unlock(a): alliberar la clau "a" (notificar que se surt de la secció crítica).

Funcions lock i unlock

Idea intuïtiva

- Suposem que el fil 1 crida a la funció lock. Si no hi ha cap fil a la secció crítica, la funció lock retorna i el fil 1 pot entrar-hi.
- A continuació arriba el fil 2 i l'N. Aquests criden també a la funció lock i es bloquegen.
- En sortir el fil 1 de la secció crítica aquest crida a la funció unlock i allibera la clau.

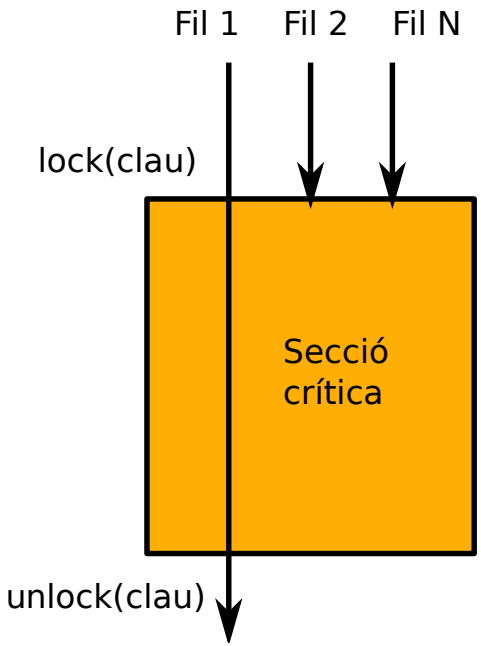

- Els fils 2 i N competeixen per adquirir la clau i entrar a la secció crítica. Només un ho aconseguirà. L'altre es bloqueja un altre cop.

Protecció de seccions crítiques

Parts diferents del codi es poden protegir amb una mateixa clau (a la secció crítica s'accedeixen a les mateixes variables compartides).

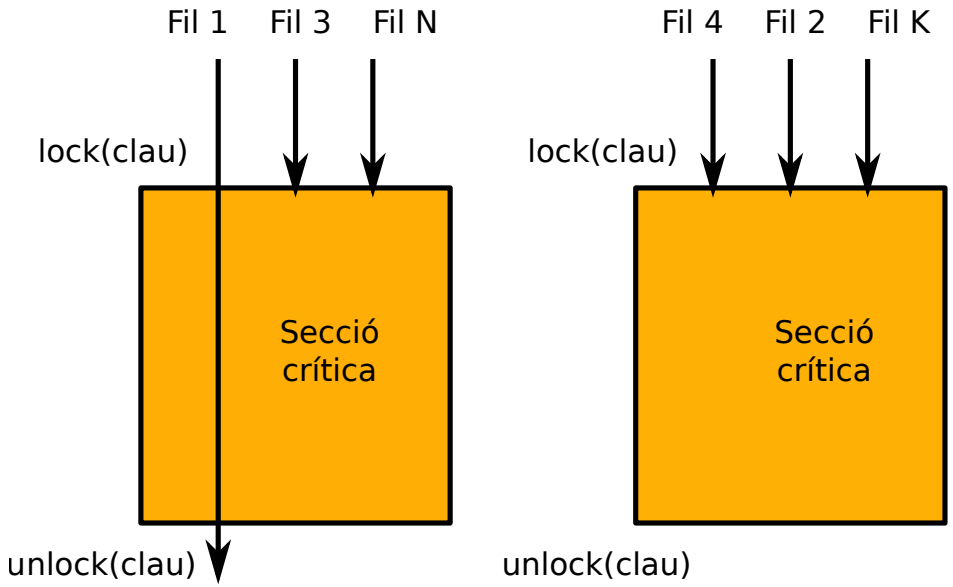

Protecció de seccions crítiques

Fent servir múltiples variables (clau1, clau2, ...) podem tenir seccions crítiques independents entre sí.

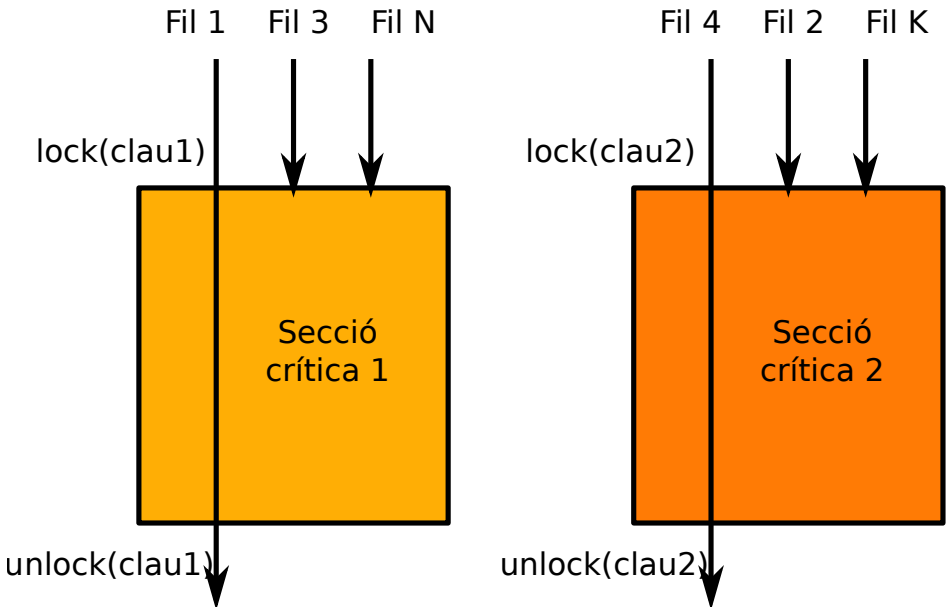

Protecció de seccions crítiques

Les seccions crítiques poden estar niades entre sí.

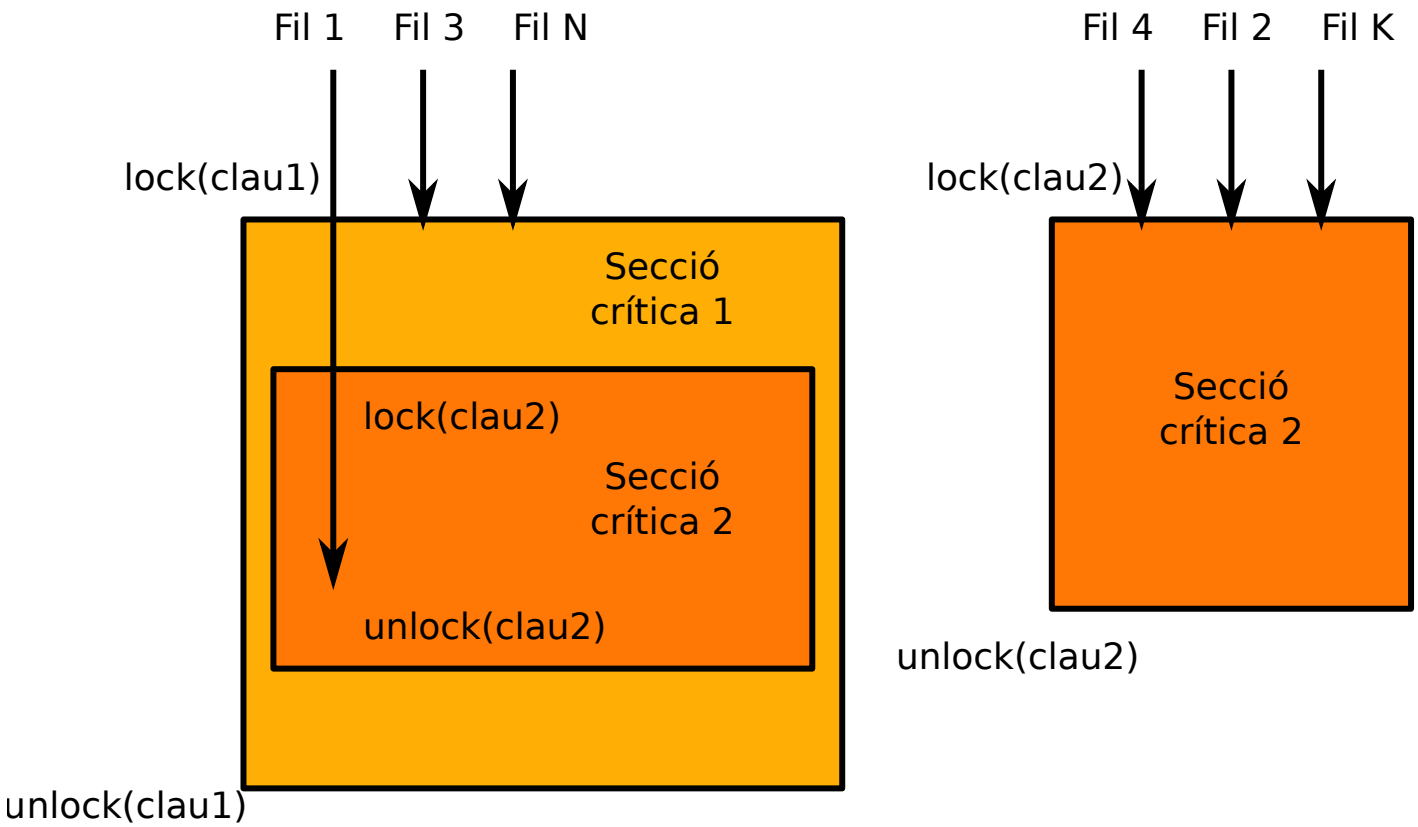

Protecció de seccions crítiques

Niar les seccions crítiques pot portar a un bloqueig total del procés – deadlock – si no es va amb compte.

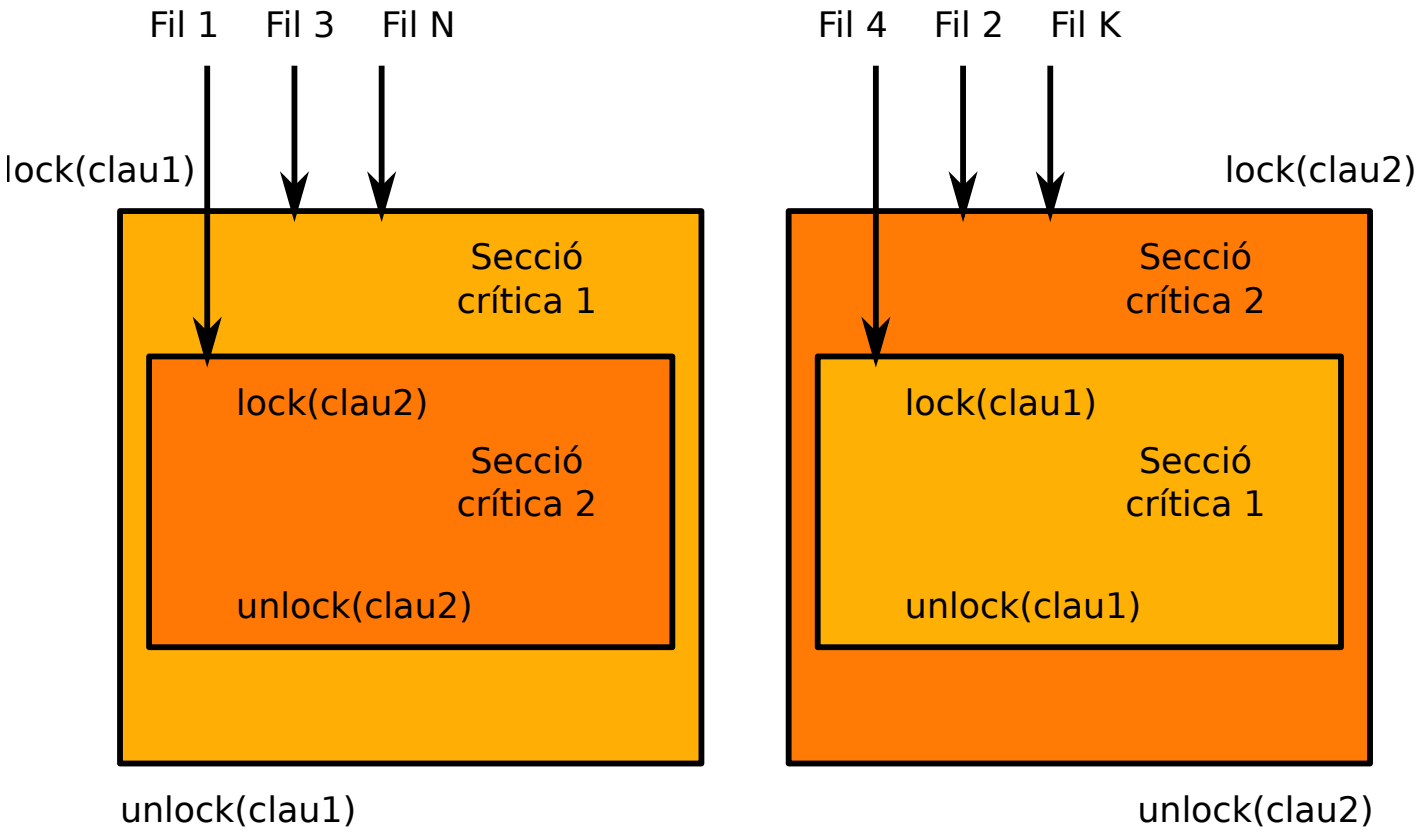

Protecció de seccions crítiques

Atenció!

- Per defecte un fil no pot agafar dues vegades la mateixa clau (la segona vegada que intenti agafar-la es bloquejarà).
- Una funció de lock es re-entrant si permet que un mateix fil agafi diverses vegades una mateixa clau. Consulteu la documentació!

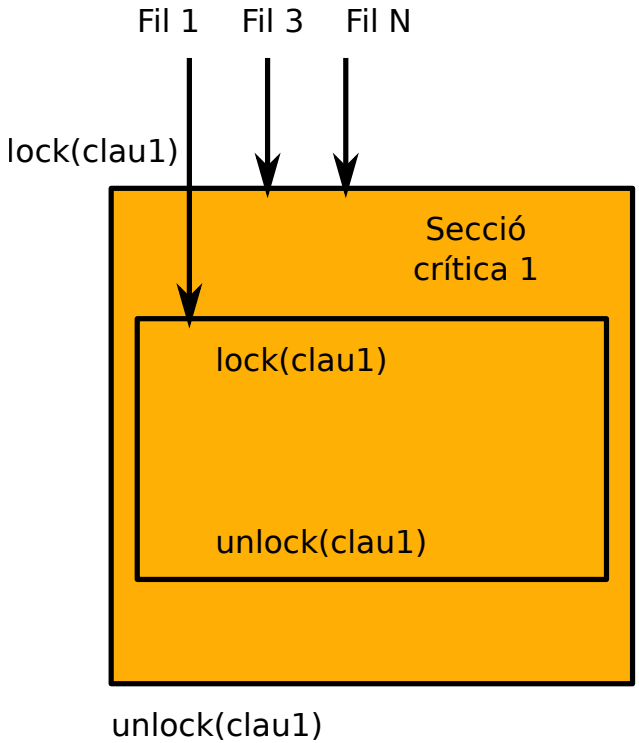

Exclusió mútua: discussió

Tingueu en compte que

- Amb lock i unlock els fils executen la secció crítica de forma seqüencial, un al darrera l'altre, encara que hi hagi múltiples processadors. Intuïvament es pot interpretar com si la secció crítica fos una instrucció atòmica: els fils veuran entrar i sortir als altres fils de la secció crítica, però no "veuran" cadascun dels passos intermitjos que els fils realitzen a dins.
- És convenient reduir al màxim l'ús de lock i unlock, ja que són crides costoses al sistema operatiu. Feu servir variables independents al fil sempre que sigui possible.
- El codi de les seccions crítiques (el codi executat de forma seqüencial) ha de ser el mínim possible.

Exclusió mútua: exemple

Veiem un exemple més el·laborat: càlcul del valor de π

$$\pi = \int_0^1 \frac{4}{1+x^2} dx$$

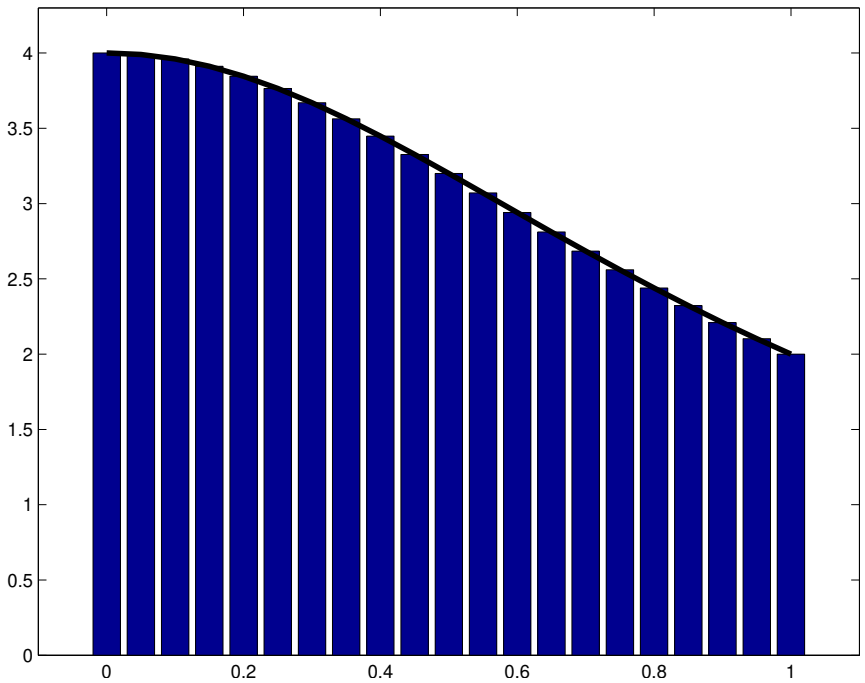


```c
#define NUM_RECTS 100000000
int main()
{
  int i;
  double mid, height, width, sum = 0.0;
  double area;

  width = 1.0 / (double) NUM_RECTS;
  for(i = 0; i < NUM_RECTS; i++) {
    mid = (i + 0.5) * width;
    height = 4.0 / (1.0 + mid * mid);
    sum += height;
  }
  area  = width * sum;
  printf("pi = %e\n", area);

  return 0;
}
```

El càlcul de l'àrea de cada rectangle és independent de la resta.

Exclusió mútua: exemple

Exemple: codi `calcul_pi_fils.c`

- El codi utilitza variables diferents (l'índex per a cada vector és diferent) per a cada fil per realitzar la suma parcial. Al final es realitza la suma total. No calen seccions crítiques.

Exemple: codi `calcul_pi_fils_semafors.c`

- El codi utilitza semàfors per accedir a la variable compartida (els veurem més endavant). El semàfor assegura que només hi ha un fil dintre de la secció crítica.
- Es redueix molt l'eficiència de l'algorisme ja que la secció crítica és massa curta: els fils s'adormen i es desperten contínuament (dormir i despertar els fils és costós).

Exclusió mútua: implementació

Com implementar l'exclusió mútua? Una forma és permetre que l'usuari deshabiliti (temporalment) les interrupcions de rellotge. D'aquesta forma s'eviten els canvis de context en una secció crítica!

Es bona idea disposar d'una funció que permeti a l'usuari habilitar i deshabilitar les interrupcions (de rellotge)?

- Si l'usuari "s'oblida" de habilitar les interrupcions no hi haurà cap canvi de context. No es pot deixar a l'usuari el control de deshabilitar o habilitar les interrupcions.
- En sistemes multiprocessador no té sentit fer-ho, ja que la deshabilitació d'interrupcions només s'aplica a la CPU que executa la instrucció, però no a la resta.

Exclusió mútua: implementació

Cal:

- Dissenyar funcions que permetin implementar una secció crítica sense necessitat d'habilitar o deshabilitar les interrupcions.

Aquestes funcions reben el nom de funcions de bloqueig (*locks*).

Tipus de bloquejos

- Per espera activa
- Per espera passiva

Tipus de bloquejos

Per espera activa

- Els fils que esperen per entrar a la secció crítica ho fan de forma activa: contínuament comproven (consumint CPU) si la clau s'allibera.
- En alliberar la clau els fils que volen entrar competeixen per adquirir la clau. Només un fil ho aconseguirà.
- No cal realitzar una crida al sistema operatiu. Es pot implementar amb la CPU en mode usuari.

Tipus de bloquejos

Per espera passiva

- Els fils que no poden entrar a la secció crítica s'adormen en una cua associada a la clau (ho fa el sistema operatiu).
- En alliberar la clau es desperten tots (o un) els fils de la cua. Aquests competeixen per adquirir la clau. Només un ho aconseguirà.
- Implica una crida al sistema operatiu.

Tipus de bloquejos

Quin tipus de clau és millor?

- Per espera activa: aplicacions amb pocs fils i si sabem que els fils esperaran poc (és a dir, que no val la pena adormir-los). S'utilitza en computació científica.
- Per espera passiva: aplicacions amb molts fils o bé si no sabem quant de temps pot trigar un fil a entrar a una secció crítica. Són el que s'utilitzen habitualment.

En alguns casos les funcions lock i unlock s'implementen amb una combinació dels dos:

- En cridar a lock, es realitzen algunes iteracions de forma activa per comprovar si la clau s'allibera.
- En cas que no s'alliberi, s'adorm el fil.

Tipus de bloquejos

Què veurem als següents temes?

- Tècniques d'espera activa
- Semàfors (espera passiva)
- Monitors (espera passiva)

Quins tipus d'algorismes podem implementar mitjançant aquests bloquejos?

Paradigmes o models de programació concurrent

Paradigmes de programació concurrent[2]

1. Paral·lelisme iteratiu
2. Paral·lelisme recursiu
3. Productors i consumidors
4. Lectors i escriptors
5. Clients i servidors
6. Parells (Peers)

A l'hora de dissenyar la nostra aplicació, cal identificar quin tipus de paradigma (o model) hem de fer servir.

[2] Els dos darrers paradigmes es veuran a Software Distribuït.

Paradigma: paral·lelisme iteratiu

- Un programa paral·lel iteratiu conté dos o més fils que realitza operacions iteratives amb bucles for i while: cada fil calcula el resultat per a un subconjunt de les dades i després es combinen.
- Exemple: producte de matrius

```
double A[N][N], B[N][N], C[N][N];

for(i = 0; i < N; i++) {
  for(j = 0; j < N; j++) {
     C[i][j] = 0.0;
     for(k = 0; j < N; j++)
        C[i][j] += C[i][j] +
                A[i][k] * B[k][j];
  }
}
```

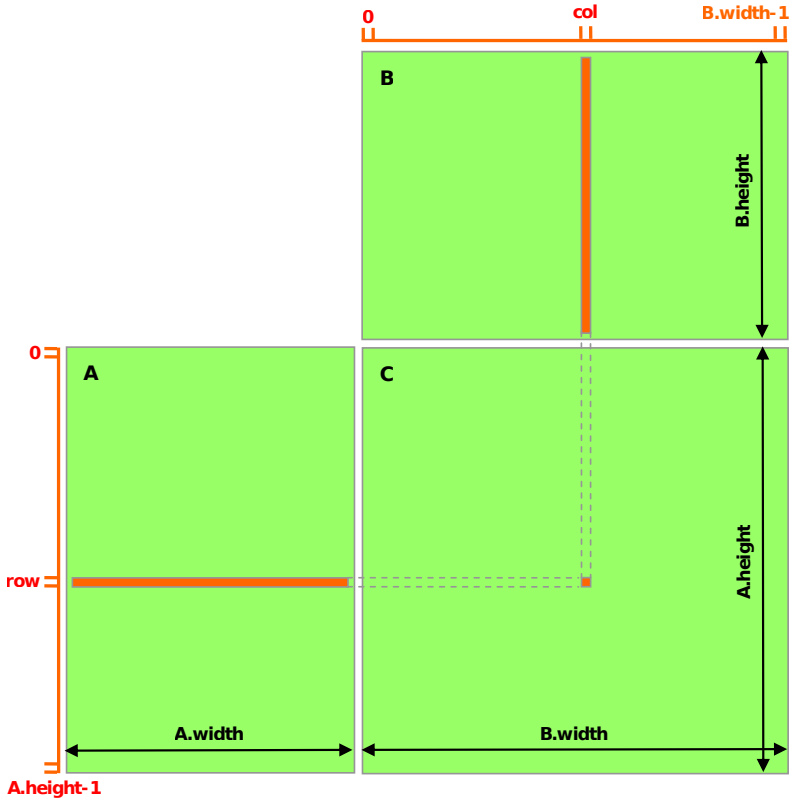

Paradigma: paral·lelisme iteratiu

- Un programa paral·lel iteratiu conté dos o més fils que realitza operacions iteratives amb bucles for i while: cada fil calcula el resultat per a un subconjunt de les dades i després es combinen.
- Exemple: suma dels valors d'un vector

```
double A[N];
double sum;

sum = 0.0;
for(i = 0; i < N; i++)
  sum += A[i];
```

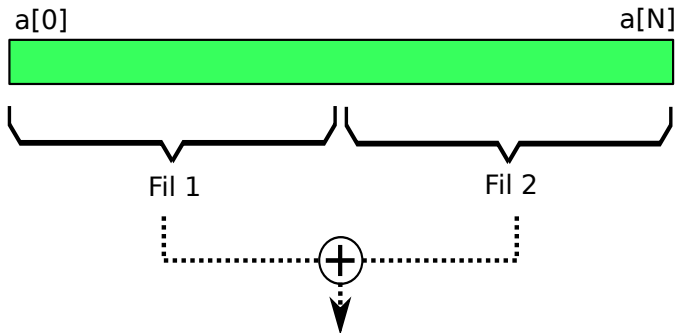

- Cada fil realitza la suma parcial per la seva banda (amb una variable local, per exemple). En acabar els dos fils es pot obtenir els resultat final.

Paradigma: paral·lelisme recursiu

- El paral·lelisme recursiu s'utilitza quan un programa té una o més funcions recursives i aquestes treballen amb parts independents de dades.
- Típicament associat a algorismes de tipus divisió-i-vèncer.
- Exemple: algorisme quicksort

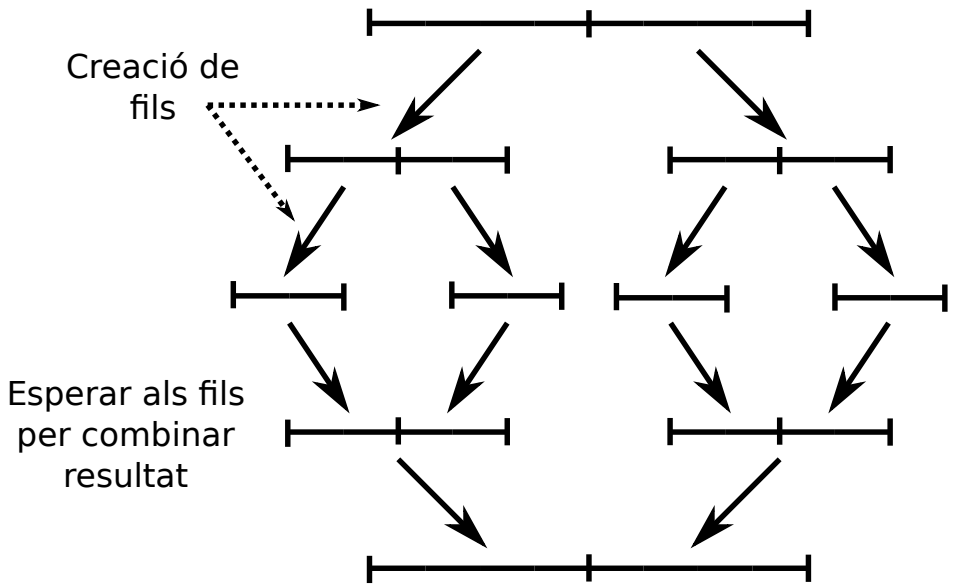

Paradigma: paral·lelisme recursiu

Respecte el paral·lelisme recursiu:

- Crear fils té un cost considerable. No és bona idea crear fils a cada recursió!
- Una solució és utilitzar una cua de tasques:
  - Es crea un determinat nombre de fils a l'inici i les tasques a realitzar s'insereixen en una cua.
  - Els fils agafen les tasques, les executen i poden crear noves tasques que s'insereixen a la cua.

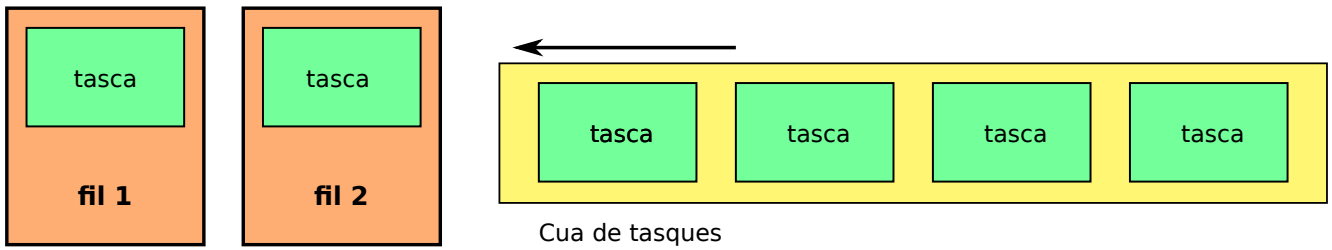

- A Programació Paral·lela aprendreu a programar-la (amb una llibreria especialitzada).

Paradigma: productors i consumidors

- Un productor processa i produeix una sortida de dades. Un consumidor processa l'entrada de dades.
- Moltes aplicacions són de tipus productor-consumidor, en què els productors i consumidors estan organitzats al llarg d'una cadena de processament.

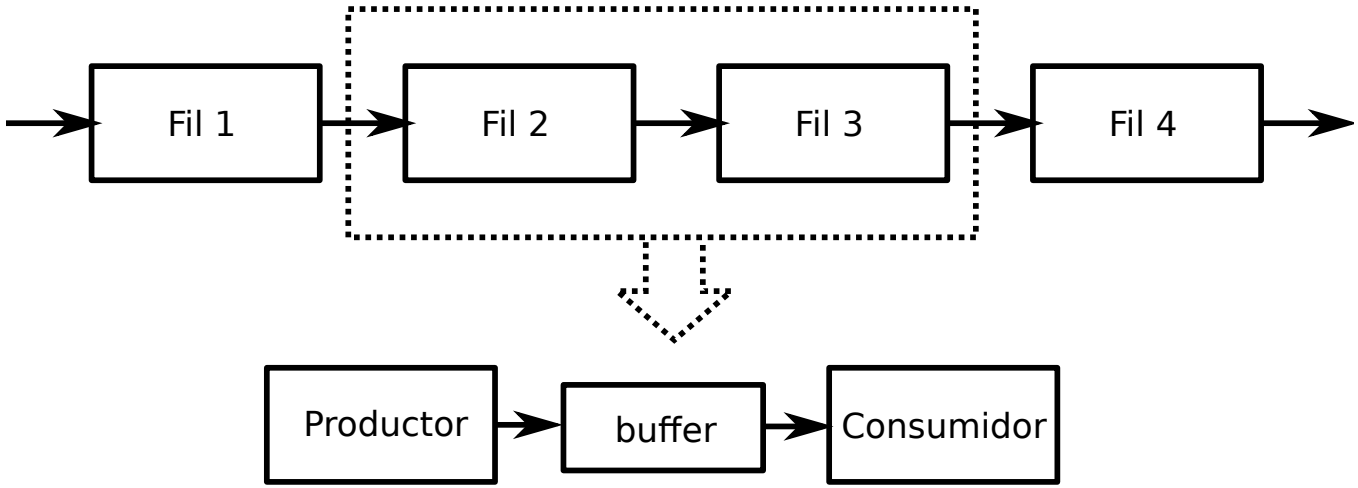

- El productor pot produir les dades a ràfegues. El *buffer* ha d'assegurar que el productor hi pugui escriure tot i que el consumidor no les pugui processar tan ràpid.

Paradigma: productors i consumidors

- Moltes vegades s'utilitza un *buffer* circular.
- Ens hem d'assegurar que el punter `write` mai superi a `read` (el productor ha d'esperar si el consumidor és lent), i que `read` mai superi a `write` (el consumidor haurà d'esperar si el productor és lent).

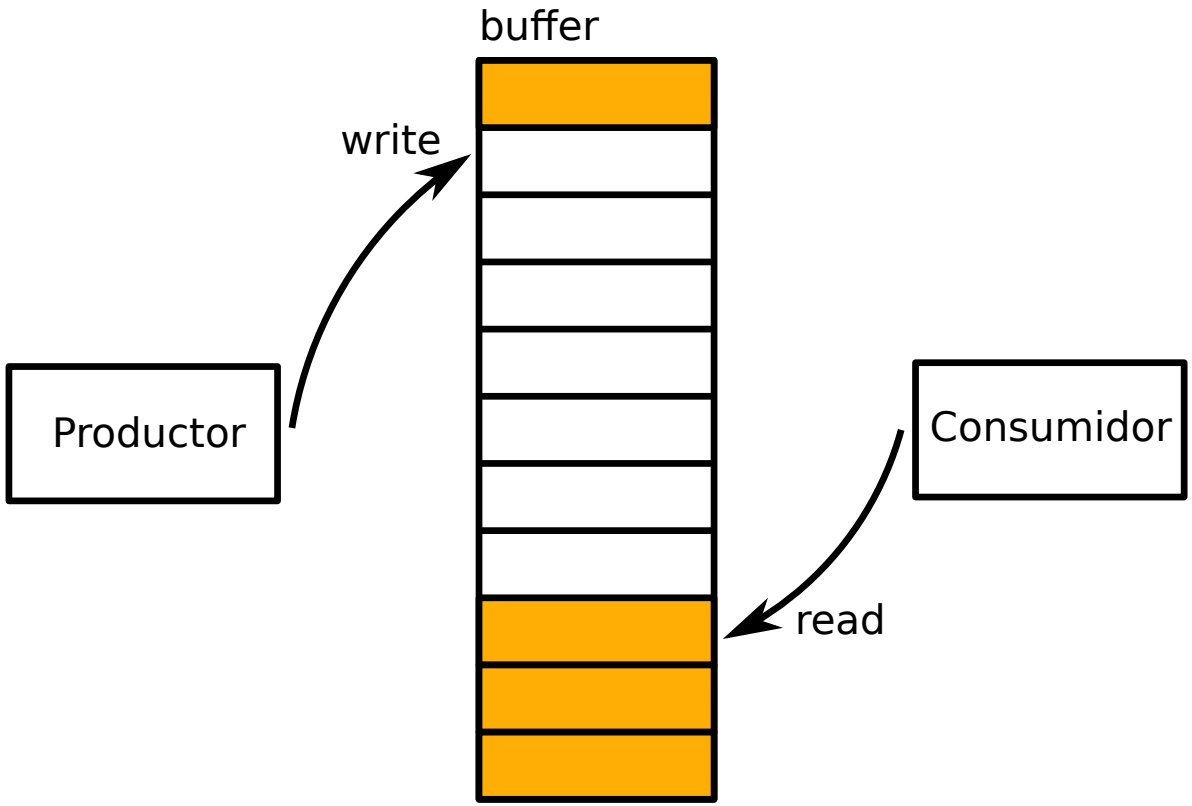

Paradigma: productors i consumidors

Hi pot haver múltiples productors i múltiples consumidors.

- Cada productor i cada consumidor és un fil.
- Els productors comparteixen l'apuntador a `write`. Els consumidors l'apuntador a `read`.

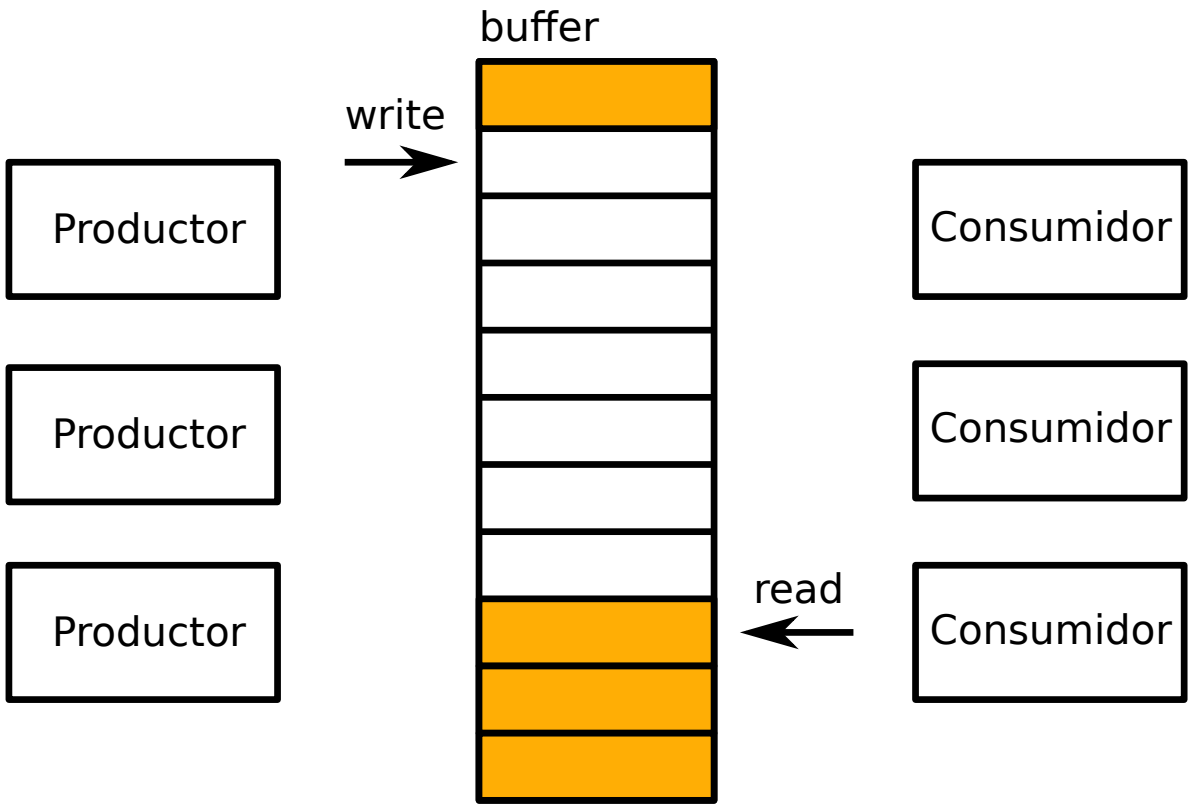

Paradigma: productors i consumidors

Típicament: un productor i múltiples consumidors

- Servidor web: dispatcher (productor) i workers (consumidors)
- La pràctica de SO2: lectura del llistat de fitxers a processar (productor) i processament dels fitxers (consumidors)

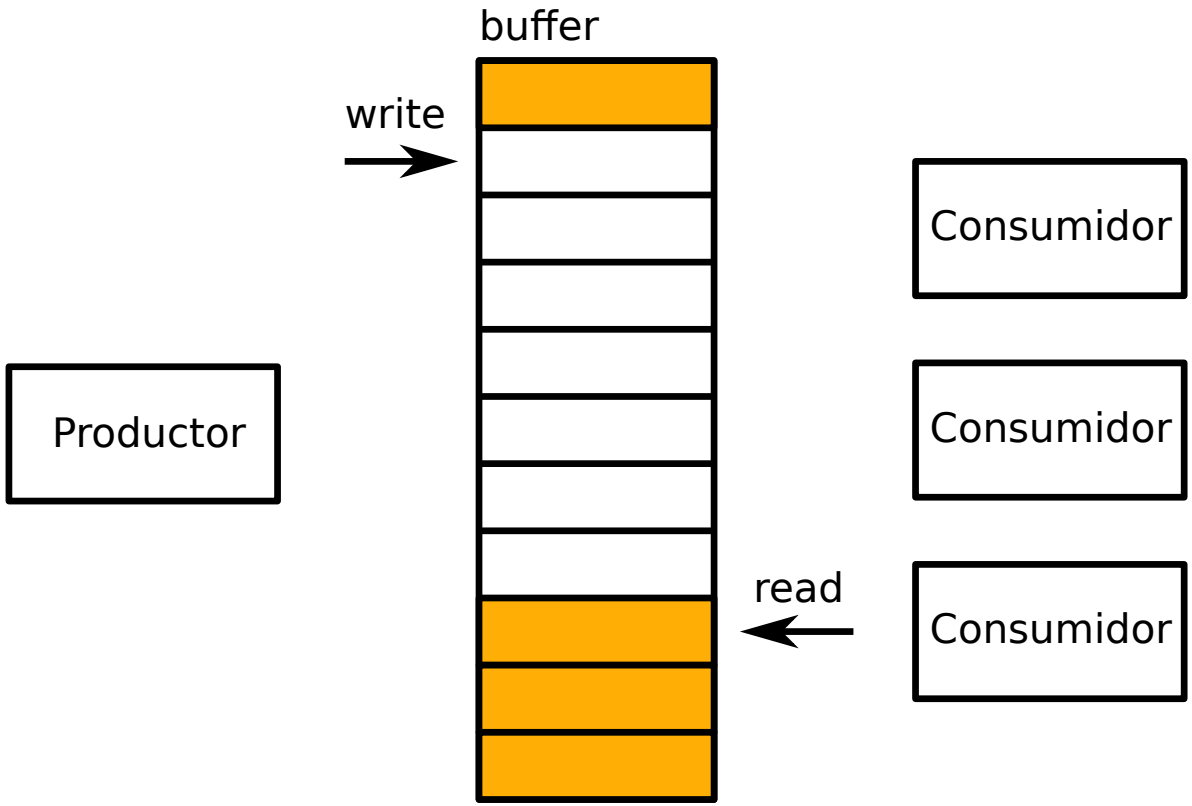

Paradigma: lectors i escriptors

En una base de dades

- Els lectors accedeixen a la base de dades i la llegeixen.
- Els escriptors hi accedeixen però per escriptura.

Per evitar interferències entre fils

- Un escriptor necessita accés exclusiu a la base de dades (o el registre de la BBDD) en escriure-hi.
- Si no hi ha cap escriptor a la base de dades (o el registre de la BBDD), múltiples lectors poden accedir a la vegada per realitzar transaccions.

Paradigma: lectors i escriptors

En programació orientada a objectes es dóna sovint aquest paradigma:

- Les funcions tipus "get" no modifiquen l'objecte (lector).
- Les funcions tipus "set" modifiquen l'objecte (escriptor).

Recordeu

- Hi pot haver múltiples lectors accedint de forma concurrent a un objecte.
- Quan hi accedeixi un escriptor hem d'assegurar que cap lector i ni escriptor hi accedeixi al mateix temps.

Consells

A l'hora de programar amb múltiples fils

- Identifiqueu quin(s) paradigma és l'adequat per implementar la vostra aplicació i utilitzeu-lo. No cal inventar res nou!
- No es pot preveure quan els fils canviaran de context. Ho decideix el sistema operatiu.
- Assegureu-vos que les regions crítiques estan protegides correctament (aprendrem a fer-ho!)
- En utilitzar una llibreria externa, assegureu-vos que aquesta és *thread-safe*, és a dir, permet l'execució de múltiples fils de forma concurrent.
  - La majoria de les funcions de la llibreria estàndard (malloc, printf, ...) són *thread-safe*. Internament tenen els mecanismes de sincronització necessaris.
  - La llibreria STL (que proveeix contenidors, iteradors, ...) no és *thread-safe*. Hem de proveir manualment els mecanismes de sincronització necessaris.

Annex: el problema dels filòsofs

Es habitual utilitzar l'anomenat "problema dels filòsofs" per exemplificar els problemes associats a la sincronització de fils. Observeu la figura:

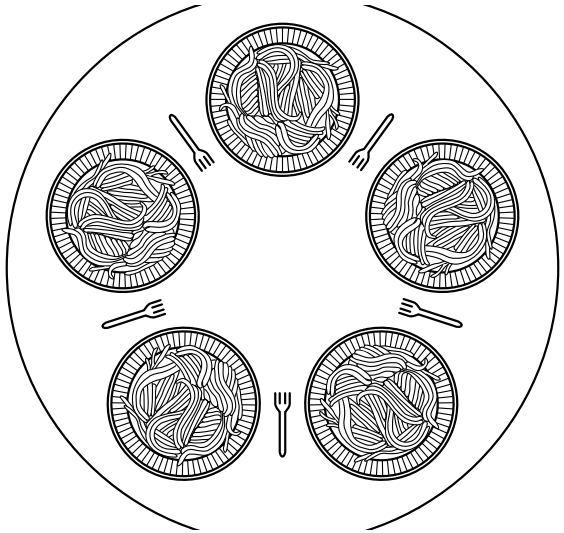

- Hi ha 5 filòsofs (un per plat de pasta) que estan pensant (i no parlen entre ells).
- Quan tenen gana, han d'agafar les dues forquilles del seu costat i menjar. En acabar de menjar, deixen les forquilles a taula.

Annex: el problema dels filòsofs

Les forquilles representen el "recurs" compartit.

- Els filòsofs no poden menjar si no disposen de les dues forquilles.
- Per menjar, primer han d'agafar una forquilla (pex la de l'esquerra) i després l'altra (pex la de la dreta).
- En acabar de menjar, deixen primer una forquilla (pex la de l'esquerra) i després l'altra (pex la de la dreta).

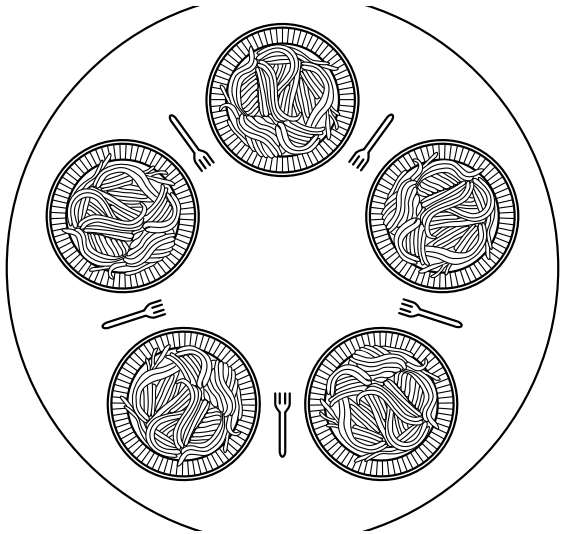

Annex: el problema dels filòsofs

Es poden produir situacions "curioses"?

- Suposem que tot els filòsofs tenen gana a la vegada.
- Tots agafen a la vegada la forquilla de l'esquerra.
- Els filòsofs voldran agafar la forquilla de la dreta però està ocupada de forma indefinida pel filòsof del costat que també vol agafar la seva forquilla de la dreta. Es produeix un deadlock.

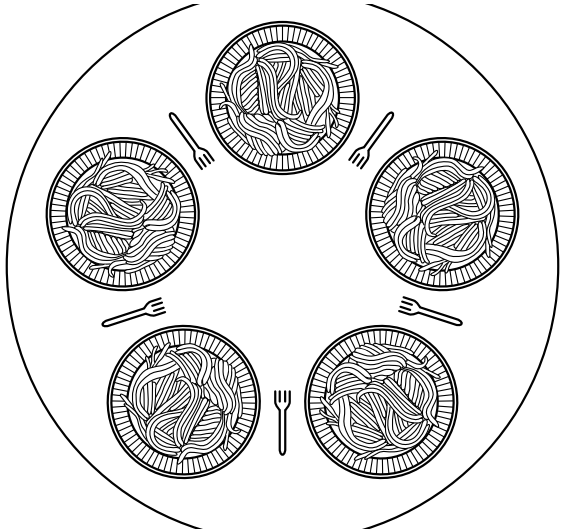

Annex: el problema dels filòsofs

Proposem una solució al problema anterior

- Un filòsof, quan té gana, comença per agafar la forquilla de l'esquerra.
- Abans d'intentar agafar la forquilla de la dreta mira si està lliure[3]. Si està lliure, agafa la forquilla i menja.
- Si no ho està, deixen la forquilla de l'esquerra, espera un temps aleatori i torna a intentar menjar.

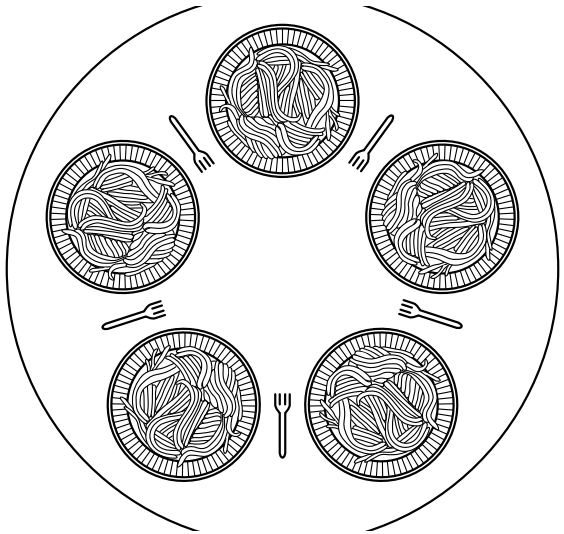

[3]Hi ha funcions C/Java que permeten saber si la clau ha estat agafada.

Annex: el problema dels filòsofs

Què pot passar?

- Existeix la possibilitat que un filòsof arribi a esperar molt de temps per menjar si els filòsofs del seu costat no paren de menjar.
- Tècnicament es diu que es produeix inanició (starvation) i no es una solució acceptable.

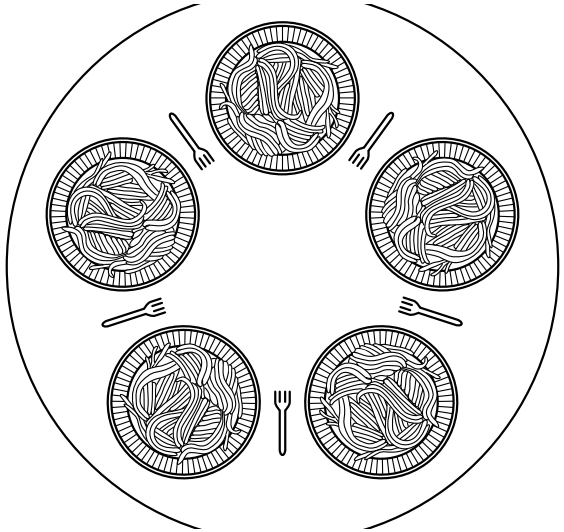

Annex: el problema dels filòsofs

Quines solucions s'han proposat?

- L'original, per Dijkstra. Es basa en numerar les forquilles del 1 al 5. Quan un filòsof vulgui menjar agafa primer la forquilla amb índex més baix. És a dir, 4 filòsofs comencen per agafar la forquilla de l'esquerra i un filòsof comença per la forquilla de la dreta. No hi ha deadlock, ni starvation!
- Utilitzar un àrbitre. Quan un filòsof vulgui menjar ha de demanar permís a l'arbitre per fer-ho. L'àrbitre només pot donar permís, en un moment determinat, a un filòsof per menjar. Amb aquesta solució es redueix el paral·lelisme.